



جامعة دمشق

كلية الهندسة المعلوماتية

السنة الرابعة

تقرير مشروع العصبونية

2020-2021

إعداد:

ولاء توما
مرام جعمور

برزاني برمجة
أحمد خضور

Related Work:

تحاول الأعمال السابقة من تنفيذ مهمة فحص سرطان الثدي في نموذجين أساسيين:

في النموذج الأول: تتوفر ملصقات على مستوى الفحص أو مستوى الثدي أو مستوى الصورة. يتم تطبيق CNN أولاً على كل من العروض القياسية الأربعة ويتم الجمع بين ال Vectors الناتجة للقيام بالتنبؤ. يمكن دمج سير العمل هذا بشكل أكبر مع التعلم متعدد المهام حيث التقييمات الإشعاعية ، مثل كثافة الثدي ، يمكن دمجها لنمذجة ثقة التصنيف. أعمال أخرى تصيغ سرطان الثدي مهمة تصنيف الامتحان على أنها تعتمد على إنتاج خريطة تنشيط التي تبرز مواقع الآفات المشبوهة.

في النموذج الثاني ، الملصقات على مستوى البكسل تشير إلى موقع النتائج الحميدة أو الخبيثة المصنف. ملصقات على مستوى البكسل تمكّن نماذج التدريب المستمدة من معمارية R-CNN أو النماذج التي تقسم صور الثدي الشعاعية إلى بقع أصغر وتدريب المصنفات على مستوى التصحيح باستخدام موقع الخبيثة النتائج يتم تجميع بعض هذه الأعمال بشكل مباشر المخرجات من المصنف على مستوى التصحيح لتشكيل مستوى الصورة تنبؤ. سنسرد بعض الأعمال المشابهة مع نسبة الدقة التي وصلت لها:

- Geras KJ, et al. (2017) High-resolution breast cancer screening with multi-view deep convolutional neural networks (0.84)
- Rodríguez-Ruiz A, et al. (2018) Detection of breast cancer with mammography: Effect of an artificial intelligence support system. (0.89)
- Becker AS, et al. (2017) Deep learning in mammography: Diagnostic accuracy of image analysis software in the detection of breast cancer. (0.81)

Abstract:


يهدف فحص التصوير الشعاعي للثدي إلى التعرف على سرطان الثدي في المراحل المبكرة من المرض ، عندما يكون العلاج أكثر نجاحًا. بالرغم من وجود التصوير الشعاعي في جميع أنحاء العالم لكن يتأثر تفسير صور الثدي بالأشعة السينية بالمعدلات المرتفعة من النتائج الإيجابية الكاذبة والسلبية الكاذبة . نقدم هنا ذكاء اصطناعي (AI) قادر على تجاوز الخبراء البشريين في التنبؤ بسرطان الثدي. نناقش في هذا التقرير كيفية التعامل مع مجموعة البيانات (data set) images histopathology breast

باستخدام CNN وبناء ال architecture الخاص بالشبكة العصبونية ثم عرض النتائج حيث تصل دقة acc لشبكتنا الى 0.86

Introduction:

سرطان الثدي هو ثاني سبب مميت مرتبط بسرطان للنساء في الولايات المتحدة. على الرغم من فحص التصوير الشعاعي للثدي خفض معدل الوفيات بسرطان الثدي ، ولا تزال موثوقيته قليلة. تطوير الشبكات العصبية التلافيفية العميقة للمساعدة في تقييم فحص التصوير الشعاعي للثدي توفر تكاليف رعاية صحية كبيرة. في هذا العمل ، نقترح بنية شبكة عصبية جديدة ومناسبة اثنين- إجراء تدريب مرحلي للتعامل بكفاءة مع مجموعة بيانات كبيرة من تصوير الثدي بالأشعة السينية عالية الدقة مع ملصقات مثبتة بالخرعة. نظهر بشكل تجريبي أن نموذجنا دقيق مثل أخصائي أشعة من ذوي الخبرة ويمكنه تحسين دقة تشخيصات أطباء الأشعة عند استخدامها كقراءة ثانية. إن نقص المتخصصين في التصوير الشعاعي للثدي يهدد التوافر في خدمات فحص الثدي حول العالم لكن يمكن أن يؤدي الذكاء الاصطناعي إلى تحسين الوصول إلى رعاية عالية الجودة للجميع.

مثال على صور ال data set بعد تحديد المناطق المطلوبة : Regions of interest :



Neural Network architecture:

عند استخدام الشبكات العصبونية لا نستخدم ال

multi-layer perceptron او ما يشبهها من البنى بسبب العدد الكبير من ال Parameters والعمليات الحسابية المعقدة التي تكلف في التعامل معها مما يأخذ وقت أكثر لذلك يتم استخدام الشبكات العصبونية الملتفة CNN التي تساعد على تجنب الكثير من العمليات المعقدة بسبب طريقة عملها.

تعريفها:

Convolutional neural network هي فئة من الشبكات العصبية الاصطناعية ANN وهي الأكثر استخداماً لتحليل الصور المرئية وقد سميت بالتلافيفية لأنها تستخدم الالتفاف بدلاً من مضاعفة المصفوفة العامة في طبقة واحدة على الأقل من طبقاتها وهي تعتمد على بنية الوزن المشترك shared-weight للمرشحات أو kernels التي تطبق على الدخل أو features.


Our Work:

Data Set:

سرطان الأبنية الغازية (IDC) هو النوع الأكثر شيوعاً لجميع سرطانات الثدي. لتعيين درجة العدوانية لعينة كاملة ، يركز علماء الأمراض عادةً على المناطق التي تحتوي على IDC. نتيجة لذلك ، تتمثل إحدى خطوات المعالجة المسبقة الشائعة لتصنيف العدوانية التلقائية في تحديد المناطق الدقيقة لـ IDC .

تتكون مجموعة البيانات الأصلية من 277.524 ألف صورة شعاعية كاملة من عينات سرطان الثدي (BCa) التي تم مسحها ضوئياً بمعدل $\times 40$. من ذلك ، تم استخراج 277.524 رقعة بحجم 50×50 (IDC 198.738 سلبي و IDC 78.786 موجب). يكون اسم ملف كل التصحيح بالتنسيق: `uxXyYclassC.png` -> مثال `idx5x1351y1101class0.png10253`. حيث u هو معرف المريض ($10253idx5$)، X هو إحداثي x للمكان الذي تم اقتصاص هذا التصحيح منه ، Y هو إحداثي y للمكان الذي تم اقتصاص هذا التصحيح منه ، و C تشير إلى الفئة حيث 0 ليس IDC و 1 هو IDC

مثال :



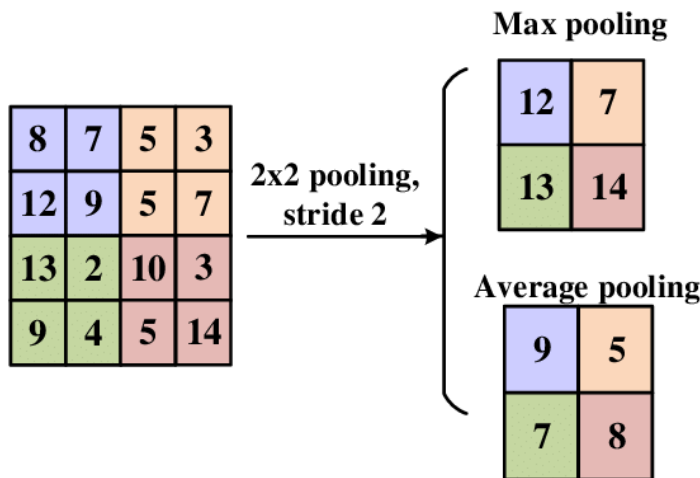
مكوناتها :

2-Pooling Layer:

إن المهمة الأساسية لهذه الطبقة هي التقليل تدريجياً للحجم وذلك لتقليل الحسابات والمعلومات خلال عملية التعلم وتطبق هذه الطبقة على كل map ناتجة من الطبقة السابقة مع أخذ بين الاعتبار أهم المميزات فيه وتنقسم هذه الطبقة إلى نوعين:


1-Max pooling

2-Average pooling



1-Convolutional Layer:

إن المهمة الأساسية لهذه الطبقة هي استكشاف المميزات Features الموجودة في الصورة مع الحفاظ على العلاقة بين المميزات الأخرى المتجاورة ويتم ذلك عن طريق ال filters وهي عبارة عن مصفوفات تضرب بالمصفوفة التي تعبر عن الصورة ويكون الخرج عبارة عن اكتشاف اغراض معينة او . features




بعض ال filters الشهيرة:

3-Fully connected layer:

إن عمل هذه الطبقة يشابه عمل ANN حيث تقوم بتغذية الشبكة العصبونية إلى الأمام Feed Forward تربط كل خلية عصبية أو نيورون في طبقة واحدة بكل نيورون في طبقة أخرى , نقوم بالعملية السابقة بعد أن نقوم بعملية flatten لابعاد مصفوفة الصورة أي تصبح عبارة عن 1 dimension وذلك لإدخالها في الشبكة العصبونية .

Operation	Filter	Convolved Image
Identity	$\begin{bmatrix} 0 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 0 \end{bmatrix}$	
Edge detection	$\begin{bmatrix} 1 & 0 & -1 \\ 0 & 0 & 0 \\ -1 & 0 & 1 \end{bmatrix}$	
	$\begin{bmatrix} 0 & 1 & 0 \\ 1 & -4 & 1 \\ 0 & 1 & 0 \end{bmatrix}$	
	$\begin{bmatrix} -1 & -1 & -1 \\ -1 & 8 & -1 \\ -1 & -1 & -1 \end{bmatrix}$	
Sharpen	$\begin{bmatrix} 0 & -1 & 0 \\ -1 & 5 & -1 \\ 0 & -1 & 0 \end{bmatrix}$	
Box blur (normalized)	$\frac{1}{9} \begin{bmatrix} 1 & 1 & 1 \\ 1 & 1 & 1 \\ 1 & 1 & 1 \end{bmatrix}$	
Gaussian blur (approximation)	$\frac{1}{16} \begin{bmatrix} 1 & 2 & 1 \\ 2 & 4 & 2 \\ 1 & 2 & 1 \end{bmatrix}$	

إن ال Dropout يضاعف تقريباً عدد مرات التكرار المطلوبة للتقارب. ومع ذلك، فإن وقت التدريب لكل حقبة Epoch أقل.



Loss Function:

يستخدم تابع الخسارة لحساب الكمية التي يجب أن يسعى النموذج إلى تقليلها أثناء التدريب. بالنسبة لنماذج الانحدار، فإن دالة الخسارة شائعة الاستخدام هي دالة الخطأ التربيعي بينما بالنسبة لنماذج التصنيف التي تتنبأ بالاحتمال، فإن دالة الخسارة الأكثر شيوعاً هي (Cross entropy) عند تركيب شبكة عصبية من أجل التصنيف. توفر Keras الأنواع الثلاثة المختلفة التالية:

binary_crossentropy:

يستخدم two exclusive classes أي يستخدم للتصنيف الثنائي فقط.

categorical_crossentropy:

يستخدم more than two exclusive classes أي يستخدم لتصنيف الفئات أو الصفوف المتعددة.

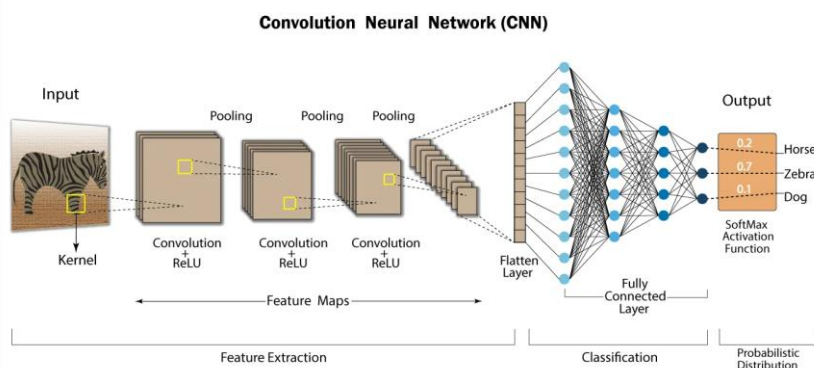
sparse_categorical_crossentropy:

يستخدم just non-exclusive classes يشابه بعمله عمل التابع السابق ولكن يختلف من ناحية الواجهة.

وقد اخترنا تابع (binary_crossentropy) لحساب الأخطاء التي تنتج عند تدريب الشبكة التي لدينا لأن في تصنيفنا الحالي نريد أن نصنف صنفين فقط أي صنفين الأول: سليم، الثاني: مصاب

4-Output layer:

إبعد تمرير المعلومات من الطبقات المتصلة الكاملة FC نستخدم تابع ال Sigmoid كتابع تحويل بدلاً من relu يقوم هذا التابع بإيجاد احتمالات كون الدخل من فئة (Class) معين أو كلاس آخر بمعنى binary classification. ويكون الشكل الكلي للشبكات العصبونية بشكل عام كالآتي:




Dropout layer:

وهي إحدى الطرق لتقليل overfitting في كل مرحلة من مراحل التدريب يتم إما إسقاط العقد الفردية أو تجاهلها باحتمالية $1-p$ أو الاحتفاظ بها باحتمالية p بحيث يتم ترك شبكة مخفضة ويتم أيضاً إزالة الحواف الواردة والصادرة للعقدة ويتم تدريب الشبكة المصغرة فقط على البيانات في تلك المرحلة ويتم بعد ذلك إعادة إدخال العقد التي تم إزالتها في الشبكة بأوزانها الأصلية. في مراحل التدريب عادة ما تكون p قيمتها 0.5 وبالنسبة لعقد الإدخال تكون أعلى من ذلك بكثير لأن المعلومات تُفقد مباشرة عند تجاهل عقد الإدخال. من خلال تجنب تدريب جميع العقد على جميع بيانات التدريب تقلل هذه الطريقة ال overfitting وهي تقلل من تفاعلات العقدة ما يؤدي إلى تعلم ميزات أكثر قوة والتي تعمم بشكل أفضل على البيانات الجديدة.

Model Accuracy:

Blue line for the training set


Orange line for validation set



Model Loss:

Blue line for the training set

Orange line for validation set



Our Model:

Model: "sequential_1"

Layer (type)	Output Shape	Param #
conv2d_2 (Conv2D)	(None, 47, 47, 32)	1568
max_pooling2d_4 (MaxPooling2D)	(None, 23, 23, 32)	0
max_pooling2d_5 (MaxPooling2D)	(None, 11, 11, 32)	0
dropout_2 (Dropout)	(None, 11, 11, 32)	0
conv2d_3 (Conv2D)	(None, 8, 8, 32)	16416
max_pooling2d_6 (MaxPooling2D)	(None, 4, 4, 32)	0
max_pooling2d_7 (MaxPooling2D)	(None, 2, 2, 32)	0
dropout_3 (Dropout)	(None, 2, 2, 32)	0
flatten_1 (Flatten)	(None, 128)	0
dense_2 (Dense)	(None, 64)	8256
dense_3 (Dense)	(None, 1)	65

Total params: 26,305
Trainable params: 26,305
Non-trainable params: 0

Training results for first epochs:

```
Epoch 1/100
55/55 - 12s - loss: 0.5814 - accuracy: 0.7060 - val_loss: 0.6097 - val_accuracy: 0.7095
Epoch 2/100
55/55 - 8s - loss: 0.4878 - accuracy: 0.7556 - val_loss: 0.5994 - val_accuracy: 0.6867
Epoch 3/100
55/55 - 8s - loss: 0.4345 - accuracy: 0.8091 - val_loss: 0.4267 - val_accuracy: 0.8257
Epoch 4/100
55/55 - 8s - loss: 0.4359 - accuracy: 0.8101 - val_loss: 0.4444 - val_accuracy: 0.8133
Epoch 5/100
55/55 - 9s - loss: 0.4248 - accuracy: 0.8169 - val_loss: 0.4484 - val_accuracy: 0.8110
Epoch 6/100
55/55 - 10s - loss: 0.4163 - accuracy: 0.8186 - val_loss: 0.5034 - val_accuracy: 0.7758
Epoch 7/100
55/55 - 9s - loss: 0.4144 - accuracy: 0.8204 - val_loss: 0.4721 - val_accuracy: 0.7957
Epoch 8/100
55/55 - 10s - loss: 0.4099 - accuracy: 0.8231 - val_loss: 0.4107 - val_accuracy: 0.8257
```

Training results for last epochs:

```
55/55 - 9s - loss: 0.3402 - accuracy: 0.8555 - val_loss: 0.4093 - val_accuracy: 0.8378
Epoch 92/100
55/55 - 9s - loss: 0.3405 - accuracy: 0.8555 - val_loss: 0.3915 - val_accuracy: 0.8383
Epoch 93/100
55/55 - 9s - loss: 0.3399 - accuracy: 0.8581 - val_loss: 0.4093 - val_accuracy: 0.8378
Epoch 94/100
55/55 - 10s - loss: 0.3392 - accuracy: 0.8564 - val_loss: 0.4077 - val_accuracy: 0.8322
Epoch 95/100
55/55 - 9s - loss: 0.3379 - accuracy: 0.8563 - val_loss: 0.4097 - val_accuracy: 0.8355
Epoch 96/100
55/55 - 9s - loss: 0.3481 - accuracy: 0.8537 - val_loss: 0.4147 - val_accuracy: 0.8345
Epoch 97/100
55/55 - 9s - loss: 0.3437 - accuracy: 0.8549 - val_loss: 0.3908 - val_accuracy: 0.8435
Epoch 98/100
55/55 - 9s - loss: 0.3431 - accuracy: 0.8557 - val_loss: 0.3939 - val_accuracy: 0.8408
Epoch 99/100
55/55 - 9s - loss: 0.3476 - accuracy: 0.8502 - val_loss: 0.4022 - val_accuracy: 0.8422
Epoch 100/100
55/55 - 9s - loss: 0.3397 - accuracy: 0.8546 - val_loss: 0.4018 - val_accuracy: 0.8352
```

2-
<https://medium.com/@amarbudhiraja/https-medium-com-amarbudhiraja-learning-less-to-learn-better-dropout-in-deep-machine-learning-74334da4bfc5>

3-
<https://towardsdatascience.com/convolutional-neural-network-for-breast-cancer-classification-52f1213dcc9>

4-
<https://ieeexplore.ieee.org/abstract/document/8308076>

5-
https://www.researchgate.net/publication/340021585_Breast_Cancer_Detection_Using_Convolutional_Neural_Networks

References:

Papers:

1-Deep Neural Networks Improve Radiologists' Performance in Breast Cancer Screening(2019) paper

2-Rodriguez-Ruiz A, et al. (2019) Stand-alone artificial intelligence for breast cancer detection in mammography: Comparison with 101 radiologists. Journal of the National Cancer Institute

3-Shen L (2017) End-to-end training for whole image breast cancer diagnosis using an all convolutional design. arXiv preprint arXiv:1708.09427.

4-Ribli D, Horváth A, Unger Z, Pollner P, Csabai I (2018) Detecting and classifying lesions in mammograms with deep learning. Scientific Reports 8(1)

5-DeepMind International evaluation of an AI system for breast cancer screening (2020) article

Websites:

1- <https://towardsdatascience.com/introduction-to-dropout-to-regularize-deep-neural-network-8e9d6b1d4386>